TEMPLATE — M2: DATA QUALITY REPORT

Exploratory Data Analysis (KMTI21133) · Bobot 10% · Dikumpulkan pada pertemuan 5

Nama tim	Capybara
Anggota dan peran	Elsa Amelia (0110223288), Risty (0110223294), Zalfa Khairunnisa (0110223269).
Judul proyek	Analisis Kualitas Data dan Persiapan Dataset Prediksi Diabetes
Pertanyaan payung	Apa perbedaan karakteristik orang yang memiliki label diabetes dan yang tidak?
Dataset	Diabetes_prediction
Tautan repositori	https://github.com/Elsaamelia55/Elsa_Risti_Zalfa_EDA
Tanggal laporan	23 Oktober 2026

1. Ringkasan

Dataset `diabetes_prediction_dataset.csv` digunakan sebagai bahan pemeriksaan kualitas data untuk proyek analisis prediksi diabetes. Dataset awal terdiri atas 100.000 baris dan 9 kolom. Pemeriksaan menemukan tiga hal utama, yaitu kategori `No Info` pada kolom `smoking_history` sebanyak 35.816 baris, 3.854 baris duplikat persis, serta keterbatasan dalam memastikan apakah baris identik benar-benar berasal dari pengamatan yang sama karena dataset tidak memiliki ID unik. Tidak ditemukan nilai kosong teknis (`NaN`), inkonsistensi kategori akibat spasi atau kapitalisasi berdasarkan pemeriksaan yang dilakukan, maupun pelanggaran terhadap aturan rentang dan kode yang digunakan. Tim mempertahankan kategori `No Info` dan menghapus duplikat persis setelah kemunculan pertama, sehingga jumlah data menjadi 96.146 baris. Setelah pembersihan, proporsi label `diabetes = 1` berubah dari 8,50% menjadi 8,82%. Secara awal, data dapat digunakan untuk analisis eksploratif dengan tetap memperhatikan keterbatasan validasi nilai dan kemungkinan penghapusan pengamatan identik yang sebenarnya berbeda. Berikut ini merupakan pertanyaan analisisnya:

- Apa perbedaan karakteristik orang yang memiliki label diabetes dan yang tidak?
- Apakah BMI orang dengan label diabetes berbeda dari orang tanpa label diabetes? (bmi, diabetes)
- Pada kelompok usia berapa label diabetes lebih banyak ditemukan? (age, diabetes)

2. Data dan cara memeriksanya

2.1 Asal data

Butir	Isi
Nama sumber	Kaggle
Tautan atau instansi	https://www.kaggle.com/datasets/iammustafatz/diabetes-prediction-dataset
Tanggal pengambilan	28 September 2026
Lisensi atau nomor izin	Data Files Original Authors
Kalimat sitasi	M. Mustofa, “Diabetes Prediction Dataset,” Kaggle. [Online]. Available: https://www.kaggle.com/datasets/iammustafatz/diabetes-prediction-dataset. [Accessed: Oct. 11, 2026]

2.2 Ukuran dan cakupan

Dataset awal terdiri atas 100.000 baris dan 9 kolom, yaitu `gender`, `age`, `hypertension`, `heart_disease`, `smoking_history`, `bmi`, `HbA1c_level`, `blood_glucose_level`, dan `diabetes`. Setiap baris merepresentasikan satu rekaman dengan karakteristik demografis, kondisi kesehatan, riwayat merokok, dan label diabetes. Namun, identitas individu pada setiap baris tidak dapat diverifikasi karena dataset tidak menyediakan ID unik. Rentang waktu pengumpulan data belum dapat dipastikan dari informasi yang tersedia dan perlu diperiksa melalui README atau dokumentasi sumber dataset.

2.3 Cara pemeriksaan

Pemeriksaan kualitas data dilakukan menggunakan Python dan pustaka pandas di Google Colab. Pemeriksaan meliputi ukuran dan tipe data, nilai kosong teknis, kategori `No Info`, konsistensi teks, duplikat persis, aturan rentang nilai numerik, serta validitas kode biner pada kolom `hypertension`, `heart_disease`, dan `diabetes`. Setelah proses cleaning, tim memeriksa kembali ukuran data, jumlah nilai kosong, duplikat tersisa, jumlah kategori `No Info`, dan distribusi label

diabetes sebelum dan sesudah pembersihan. Validasi terhadap sumber asli, identitas unik setiap pengamatan, serta kebenaran nilai berdasarkan rekam medis tidak dapat dilakukan hanya dari dataset yang tersedia.

3. Temuan kualitas data

Dimensi	Kolom	Masalah	Jumlah	Keparahan	Keputusan
Completeness	smoking_history	Kategori No Info menunjukkan informasi riwayat merokok tidak tersedia atau tidak diketahui.	35.816 baris (35,82%)	Tinggi	Dipertahankan sebagai kategori tersendiri karena nilai sebenarnya tidak diketahui.
Uniqueness	Seluruh Kolom	Terdapat baris dengan seluruh nilai yang identik.	3.854 baris duplikat setelah kemunculan pertama	Sedang	Baris duplikat persis dihapus setelah kemunculan pertama.
Consistency	gender, smoking_history	Tidak ditemukan perbedaan jumlah kategori akibat spasi di awal/akhir atau perbedaan kapitalisasi.	0	Rendah	Nilai teks dipertahankan tanpa perubahan.
Validity	age, bmi, HbA1c_level, blood_glucose_level	Tidak ditemukan nilai yang melanggar aturan rentang yang ditetapkan dalam pemeriksaan.	0	Rendah	Dipertahankan
Validity	hypertension, heart_disease, diabetes	Tidak ditemukan nilai di luar kode biner 0 dan 1.	0	Rendah	Dipertahankan
Completeness	Seluruh kolom	Tidak ditemukan NaN	0	Rendah	Tidak dilakukan tindakan apapun
Accuracy	Seluruh kolom	Kebenaran nilai terhadap kondisi individu yang sebenarnya tidak dapat diverifikasi hanya dari dataset.	Belum dapat ditentukan	Belum dapat ditentukan	Dicatat sebagai keterbatasan pemeriksaan; diperlukan sumber pembanding atau konfirmasi pemilik data.

Dimensi: Kelengkapan · Keunikan · Konsistensi · Validitas · Akurasi. Keparahan: Tinggi · Sedang · Rendah. Tambahkan baris bila perlu; sepuluh baris adalah jumlah yang lazim, bukan batas.

3.1 Pola nilai kosong

Walaupun tidak ditemukan NaN, kolom smoking_history memiliki 35.816 nilai No Info atau sekitar 35,82% dari seluruh baris. Nilai tersebut menunjukkan informasi riwayat merokok tidak tersedia atau tidak diketahui, tetapi penyebabnya tidak dapat dipastikan hanya berdasarkan dataset. Hipotesis sementara yang dapat digunakan adalah MNAR (Missing Not At Random), yaitu kemungkinan bahwa ketersediaan informasi berkaitan dengan karakteristik yang tidak tercatat atau proses pengumpulan data. Namun, hipotesis ini belum dapat dibuktikan. Pola tersebut juga dapat berkaitan dengan mekanisme pengumpulan data lain, sehingga diperlukan informasi tambahan dari pemilik atau sumber dataset.Untuk kolom lainnya, tidak ditemukan nilai kosong teknis yang melebihi ambang 5%. Oleh karena itu, tidak ada kolom lain yang perlu dianalisis lebih lanjut dalam bagian pola missingness berdasarkan hasil pemeriksaan saat ini.

Kolom	Persen kosong	Dugaan	Dasar dugaan
-	-	-	-
-	-	-	-
-	-	-	-
-	-	-	-
-	-	-	-

4. Keputusan pembersihan dan alasannya

Bagian dengan bobot terbesar pada rubrik (30). Yang dinilai bukan pilihan Anda, melainkan apakah pilihan itu punya dasar. Isi minimal lima keputusan. Untuk setidaknya satu keputusan, sebutkan alternatif yang Anda pertimbangkan dan alasan menolaknya.

Contoh pengisian yang bernilai penuh

Masalah	Kolom `durasi_layanan` kosong pada 11% baris
Dugaan pola	MAR. Kekosongan terpusat pada layanan daring (38% kosong) dibanding layanan luring (2%), karena sistem daring tidak merekam durasi.
Keputusan	Dibiarkan kosong dan ditambahkan kolom penanda `durasi_tersedia`.
Alasan	Kekosongannya bermakna, bukan hilang. Mengisi dengan rata-rata akan menciptakan durasi untuk layanan yang memang tidak mengukur durasi.
Alternatif ditolak	Imputasi median per kelompok ditolak karena akan menyamarkan perbedaan nyata antara kedua jenis layanan, padahal perbedaan itu justru pertanyaan analisis kami.
Dampak	Tidak ada baris yang hilang. Analisis durasi dibatasi pada 89% baris, dan batasan ini disebutkan di Bagian 6.

Perhatikan bedanya: "Kolom X diisi dengan median" adalah deskripsi tindakan. Kutipan di atas adalah justifikasi. Rubrik membedakan keduanya.

Keputusan tim Anda

Keputusan 1

Masalah	Terdapat 3.854 baris duplikat persis setelah kemunculan pertama.
Dugaan pola	Baris memiliki nilai identik pada seluruh kolom. Penyebab duplikasi belum diketahui.
Keputusan	Menghapus duplikat
Alasan	Mengurangi pengulangan baris yang berpotensi memengaruhi hasil analisis.
Alternatif ditolak	Mempertahankan semua baris karena belum tersedia ID unik. Alternatif ini ditolak karena baris identik dapat memberikan bobot berlebih pada pola tertentu.
Dampak	Jumlah baris berkurang dari 100.000 menjadi 96.146.

Keputusan 2

Masalah	Kolom smoking_history memiliki 35.816 nilai No Info.
Dugaan pola	Informasi riwayat merokok tidak diketahui atau tidak tersedia; mekanismenya belum dapat dipastikan.
Keputusan	Mempertahankan No Info sebagai kategori tersendiri.
Alasan	Mengganti nilai tersebut dengan kategori tertentu dapat menimbulkan informasi yang tidak didukung data.
Alternatif ditolak	Menghapus seluruh baris No Info. Alternatif ini ditolak karena akan menghilangkan sekitar 35,82% data awal.
Dampak	Setelah penghapusan duplikat, kategori No Info berjumlah 32.887.

Keputusan 3

Masalah	Tidak ditemukan inkonsistensi teks akibat spasi tepi atau kapitalisasi pada kolom teks yang diperiksa.
Dugaan pola	Nilai kategori sudah konsisten menurut pemeriksaan tersebut.
Keputusan	Mempertahankan nilai teks tanpa perubahan.
Alasan	Tidak ada bukti bahwa normalisasi tambahan diperlukan.
Alternatif ditolak	Mengubah seluruh nilai teks secara otomatis. Alternatif ini tidak dipilih karena tidak ditemukan masalah yang memerlukan perubahan.
Dampak	Tidak ada kategori yang berubah akibat normalisasi teks.

5. Dampak pembersihan terhadap data

5.1 Sebelum dan sesudah

Ukuran	Sebelum	Sesudah	Catatan
Jumlah baris	100000	96146	
Jumlah kolom	9	9	
Total sel kosong	0	0	
Baris duplikat	3854	0	

5.2 Dampak terhadap sebaran

Kolom	Mean sebelum	Mean sesudah	Pergeseran	Penilaian
BMI	27.3207671	27.32		

6. Keterbatasan

Pembersihan dataset ini memiliki beberapa keterbatasan. Pertama, penyebab munculnya baris duplikat persis belum dapat diketahui karena dataset tidak memiliki ID unik yang dapat digunakan untuk memastikan identitas setiap pengamatan. Oleh sebab itu, penghapusan duplikat didasarkan pada kesamaan seluruh nilai kolom, bukan pada kepastian bahwa baris tersebut merupakan catatan berulang dari individu yang sama. Kedua, kolom smoking_history memiliki kategori No Info dalam jumlah besar. Mekanisme ketidaktersediaan informasi tersebut belum dapat dipastikan, sehingga dugaan MNAR hanya merupakan hipotesis awal. Jika nilai yang tidak diketahui berkaitan dengan karakteristik tertentu, analisis hubungan riwayat merokok dengan diabetes berpotensi mengalami bias. Ketiga, pemeriksaan validitas hanya menggunakan aturan rentang dan kode yang ditetapkan. Pemeriksaan tersebut tidak dapat memastikan bahwa nilai usia, BMI, HbA1c, glukosa darah, maupun status diabetes benar-benar sesuai dengan kondisi individu yang sebenarnya. Verifikasi tersebut membutuhkan sumber pembanding atau konfirmasi dari pemilik data. Asumsi yang masih perlu dikonfirmasi meliputi asal-usul duplikat, makna kategori No Info, definisi setiap variabel, serta prosedur pengumpulan data. Keterbatasan ini perlu diperhatikan ketika dataset digunakan untuk analisis eksploratif maupun pemodelan prediksi diabetes.

7. Penanganan data pribadi

Lanjutan pekerjaan pertemuan 3. Nyatakan apakah data olahan masih memuat data pribadi, dan bagaimana penanganannya dijaga selama pembersihan.

Butir	Keterangan
Kolom data pribadi pada data olahan	
Tindakan penanganan yang diterapkan	
Nilai k pada data yang diunggah	
Status repositori (publik atau privat)	
data/raw/ masuk .gitignore	

8. Langkah berikutnya

- Menyelesaikan dan memverifikasi statistik sebelum-sesudah pembersihan, termasuk mean, median, dan standar deviasi kolom bmi.
- Melakukan analisis distribusi setiap variabel, baik numerik maupun kategorikal, untuk memahami karakteristik dataset.
- Menganalisis hubungan awal antara variabel prediktor dan target diabetes tanpa langsung menyimpulkan hubungan sebab-akibat.
- Memeriksa potensi ketidakseimbangan kelas target dan mempertimbangkan dampaknya terhadap evaluasi model.
- Mengonfirmasi sumber dataset, lisensi, makna kategori No Info, dan mekanisme duplikasi apabila informasi tersebut tersedia.